A decorative background featuring a network diagram with nodes and connecting lines, primarily in light gray, with some nodes highlighted in blue. The diagram is positioned in the top-left and bottom-right corners of the slide.

Deep Learning com Python



Olá!

Yan Coltro

Mestre em TCA

Backend Developer

Professor do curso de SI FAG



<https://www.linkedin.com/in/yan-coltro/>



<https://github.com/yancoltro>

Deep Learning?

O que é? Como funciona?
De onde veio?





1.

Aprendizado de máquina (ML)

Uma introdução

ML = IA || Big Data ?

Big Data

- Google processe mais de 20 petabytes de informação por dia
- Todos os dias são criados 2,5 quintilhões de bytes


- Volume impraticável para ser analisado por humanos
- Big Data é usado em conjuntos complexos e com muitas variáveis (features)
- Deep Learning, Redes Neurais necessitam de grandes volumes de dados para treinamento

ML = IA || Big Data ?

IA

- ◎ O cérebro da IA é a ML
- ◎ Necessidade de interagir com o ambiente
- ◎ Sensores, atuadores, feedback espacial

- ◎ Siri, um bom exemplo de IA
- ◎ Tesla, um bom exemplo de IA
- ◎ Boston Dynamics, um bom exemplo de IA





Machine learning é um ramo da ciência da computação que se concentra no uso de dados e algoritmos para imitar a maneira como os humanos aprendem, melhorando gradualmente sua precisão.

Tipos de aprendizado

Supervisionado

Dados rotulados

Discretas: Classificação

!Discretas: Regressão

Não Supervisionado

Agrupamento de dados
com base em
similaridades

Por reforço

Domínios específicos

Recompensas
associadas a alterações
no ambiente e seu
estado

Aprendizado Supervisionado



Exemplos do aprendizado supervisionado

Caixa de e-mails (**Classificação**)

Trabalho/Promoções/Fóruns....

Classificar antes, treinar depois

Identificar palavras chaves,
remetente, etc

****Classes são discretas e finitas**



Exemplos do aprendizado supervisionado

Preços de imóveis (**Regressão**)

Recebe parâmetros (m^2 , bairro, tipo, banheiros, ...)

$f(x)$ = valor da casa

$f(100m^2, A, M, \dots) = 100000$

$f(\mathbf{w1} * 100m^2 + \mathbf{w2} * A + \dots) = 100000$


****Classes são indiscretas e infinitas**



Árvores



Máquinas de vetor de suporte (SVM)



Aprendizado Não Supervisionado




Exemplos do aprendizado não supervisionado

PLN

Agrupar por contexto

Sentimentos por contexto

Tradução automática



Exemplos do aprendizado não supervisionado

Modelos generativos

Geração de imagens

Colorir imagens


Sintetizar imagens

Geração de texto


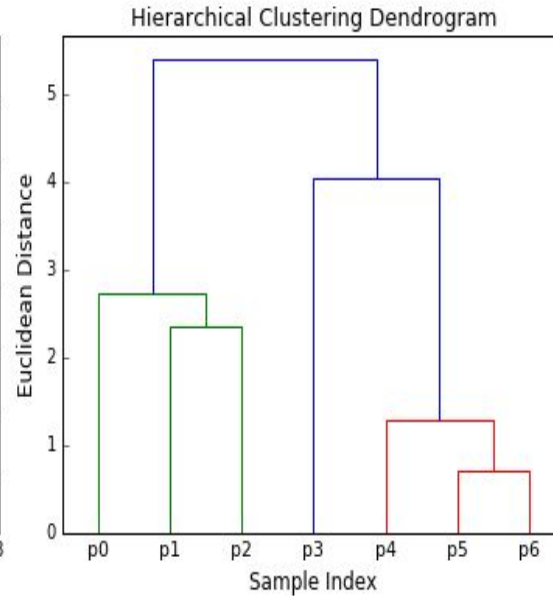

Alteração de expressões



K-means



Cluster hierárquico



Aprendizado Por reforço



Exemplos do aprendizado por reforço

Controle de autônomos

Manter-se na faixa

Respeitar a sinalização

Melhor rota



Exemplos do aprendizado por reforço

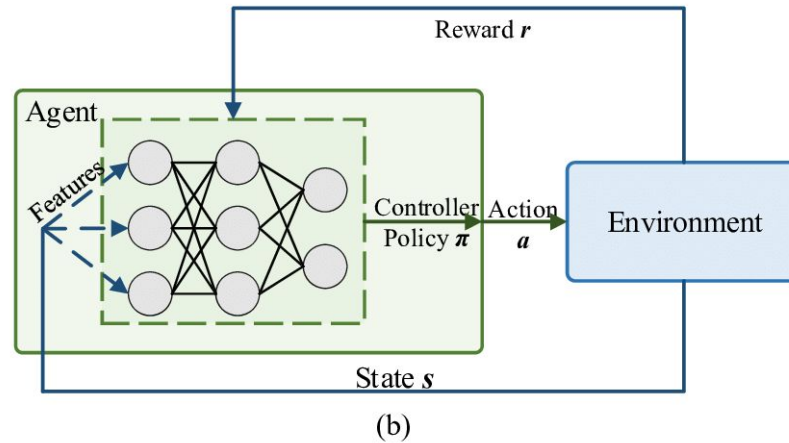
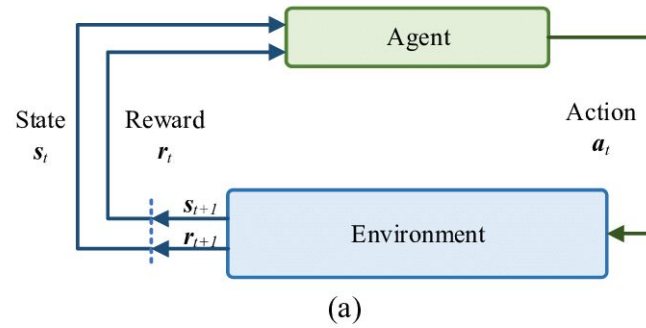
Carteira de ações

Venda de ações


Valor maximizado da carteira



Q-Learning



Bônus



A decorative network diagram in the top-left corner, featuring a complex web of interconnected nodes and lines, with some nodes highlighted in blue.

2.

Componentes e processos de uma solução ML

Componentes

- ⊙ Learner
- ⊙ Training data
- ⊙ Representation
- ⊙ Goal
- ⊙ Target

Processos

- ⊙ Coleta de dados
- ⊙ Processamento de dados
- ⊙ Caso de teste
 - Treinamento
 - Teste
 - Validação


****Overfitting!!!!!!!**

A decorative network diagram in the top-left corner, featuring a complex web of interconnected nodes and lines. The nodes are represented by small circles, some of which are larger and have concentric circles, suggesting different levels or types of nodes. The lines are thin and gray, connecting the nodes in a non-linear fashion.

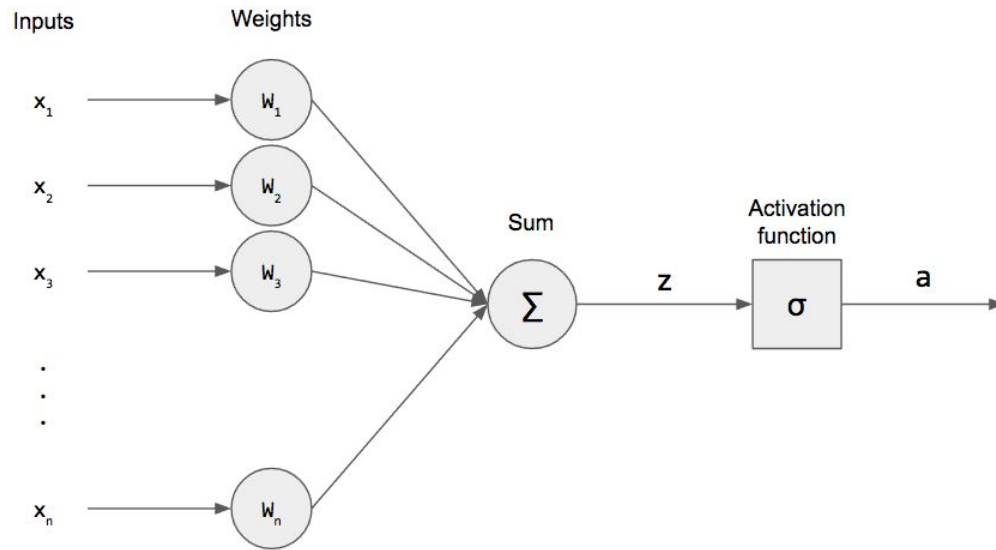
3.

Redes Neurais


1957, Frank Rosenblatt



Perceptron



Multilayer Perceptron





****Teorema da aproximação universal**



“

*Uma **rede neural**
não é um programa fixo, mas sim
um modelo, um sistema que
processa informações ou entradas*

- 
- 
- ◎ O processamento da informação ocorre em sua forma mais simples, sobre elementos simples chamados **neurônios**.
 - ◎ Os neurônios estão conectados e trocam sinais entre eles por meio de links de conexão.
 - ◎ As ligações de conexão entre os neurônios podem ser mais fortes ou mais fracas, e isso determina como a informação é processada.
 - ◎ Cada neurônio tem um estado interno que é determinado por todas as conexões de entrada de outros neurônios.
 - ◎ Cada neurônio tem uma **função de ativação** diferente que é calculada em seu estado e determina seu sinal de saída.

Como identificar redes neurais

Arquitetura

- ◎ Feedforward
- ◎ Multicamada
- ◎ Cama única
- ◎ Número de neurônios

Aprendizagem

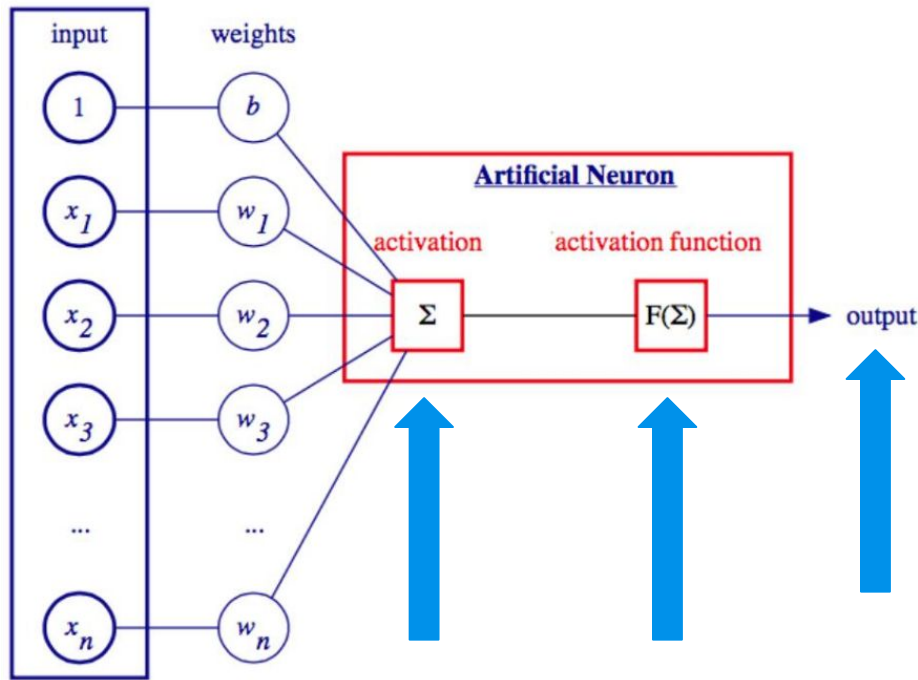
- ◎ Gradiente descendente
- ◎ Retropropagação

A decorative network diagram in the top-left corner, featuring a complex web of interconnected nodes and lines, with some nodes highlighted in grey and others in white.

4.

Partes de uma Rede Neural

Uma visão geral



Inputs: Dados que alimentarão a rede

Weights: Serão eles que serão ajustados durante o aprendizado

Activation: Função responsável por definir se algum neurônio atendeu as condições pra ser ativado (função de ativação)

Activation Function: Se o neurônio foi ativado, verifica se o limiar de valor atingido é suficiente para ativar a camada de saída (função de ativação ou limiar)

Output: Resultado da rede (classes ou valores)

Bias: Tendência da rede

Camadas: Neurônios ocultos da rede

A decorative network diagram in the top-left corner, featuring a complex web of interconnected nodes and lines, with some nodes highlighted in blue and others in grey.

5.

Deep Learning



Fundamentos



*Uma **Deep Learning** não aprende simplesmente a prever a saída Y dada a entrada X ; ela também entende os recursos básicos da entrada. É capaz de aprender abstrações de recursos de exemplos de entrada, entender as características básicas dos exemplos e fazer previsões com base nessas características. Este é um nível de abstração que está faltando em outros algoritmos básicos de aprendizado de máquina (ML) e em redes neurais superficiais.*

Como a Deep Learning aprende?

- ⦿ Aprendizado de recursos
- ⦿ Grande volume de dados
- ⦿ Sem necessidade de engenharia de recursos



Aplicações atuais da Deep Learning



Duplex



AlphaGo



Amazon Rekognition



As razões para a popularidade da Deep Learning

- ◎ Multilayer Perceptron - + 50
- ◎ Backpropagation - 1986
- ◎ Convolucionais - 1990
- ◎ Memória de curto prazo - 1997
- ◎ Muitos dados
- ◎ Melhores máquinas
- ◎ Melhor conexão
- ◎ GPU e CPU

A decorative network diagram in the top-left corner, featuring a complex web of interconnected nodes and lines, with some nodes highlighted in blue.



6.

Redes Convolucionais




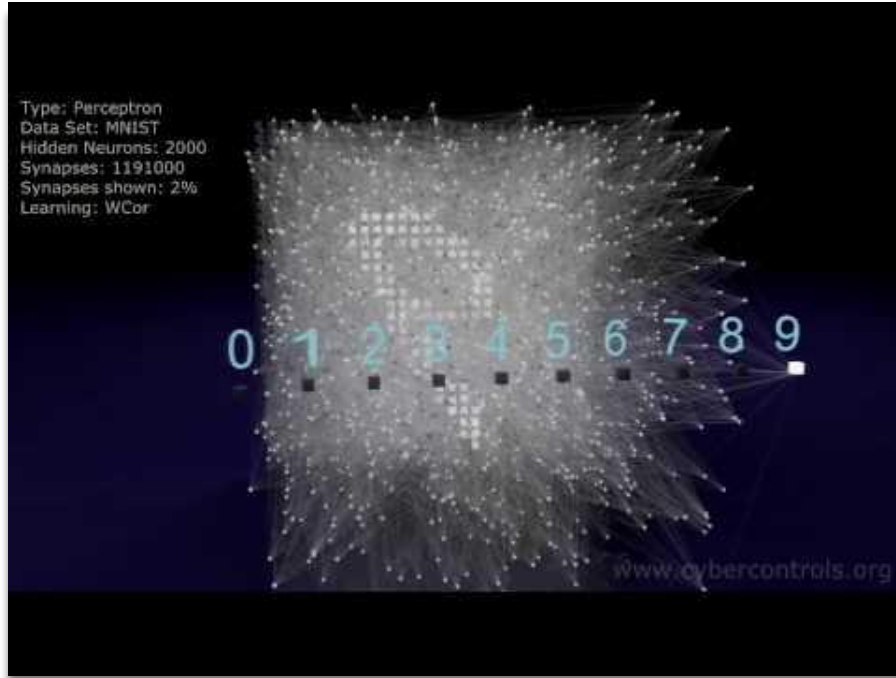
O assunto de hoje



*A **visão** é sem dúvida o sentido humano mais importante. Contamos com ele para quase todas as ações que tomamos. Mas o reconhecimento de imagem tem sido (e de certa forma ainda é), por muito tempo, um dos problemas mais difíceis da ciência da computação.*

- 
- 
- ◎ CNNs conectam neurônios próximos (ótimo para imagens)
 - ◎ Compartilhamento de parâmetros (pesos / - overfitting)

Funcionamento



Conceitos

Slice

Dados de entrada

Stride

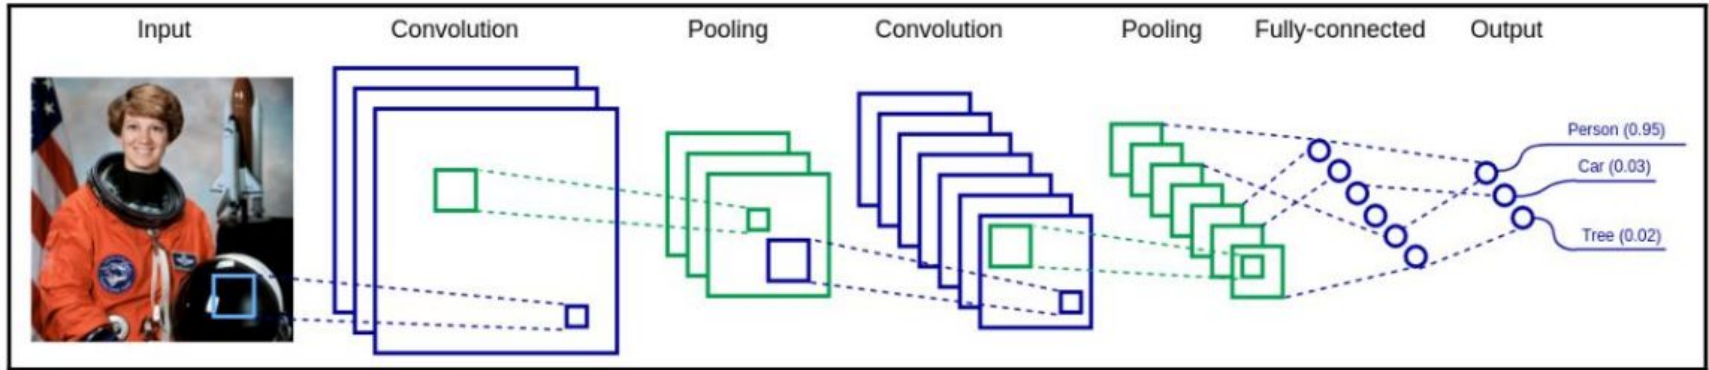
Tamanho da
janela de
transformação

Convolution

Produto da
aplicação de
filtros

Pooling

Produto dos
destaques da
convolução



Mão na massa

